

Étude Cartographique & Revue Systématique de Littérature

Impact du déséquilibre des données sur la performance des modèles de détection de fraude

Msouhli Rahil & Sekkat Israa
Filière : Master DSBD | Année 2025–2026

Table des matières
Partie 1 — Étude Cartographique
1.1 Méthodologie de recherche
1.2 Questions cartographiques (RQ1 – RQ5)
1.3 Stratégie de recherche : blocs de concepts, mots-clés, équations
1.4 Sources documentaires et sélection du corpus
1.5 Grille cartographique (20 articles)
1.6 Résultats : tendances, clusters, limites et gap
Partie 2 — Revue Systématique de Littérature (RSL)
2.1 Objectif et questions de recherche (RQ1 – RQ6)
2.2 Stratégie de recherche et chaîne de requête
2.3 Critères d'inclusion et d'exclusion
2.4 Formulaire d'extraction des données
2.5 Résultats par question de recherche
2.6 Limites, défis et perspectives
2.7 Positionnement de la contribution

Partie 1 — Étude Cartographique

1.1 Méthodologie de recherche

L'objectif essentiel d'une étude cartographique systématique est de fournir une vue d'ensemble structurée du domaine de la détection de fraude et du traitement du déséquilibre des données, en identifiant la quantité de travaux existants, en classant les types de recherches disponibles et en mettant en évidence les tendances d'évolution du domaine. Notre démarche s'articule autour de cinq étapes : (1) définition des questions cartographiques, (2) élaboration de la stratégie de recherche, (3) sélection rigoureuse des études, (4) attribution de mots-clés basée sur l'analyse des résumés, et (5) extraction des données et cartographie.

1.2 Questions cartographiques

Les questions cartographiques sont larges et exploratoires : elles servent à orienter la recherche documentaire avant de formuler une question plus précise pour la RSL. Elles suivent le modèle : « Que publie-t-on sur ... ? ».

ID	Question cartographique	Motivation principale
RQ1	Quelles sont les tendances des publications sur la détection de fraude et le déséquilibre des données (année, source, région) ?	Reconnaître la répartition temporelle et géographique des travaux et orienter les recherches futures.
RQ2	Quelles techniques de rééquilibrage sont les plus étudiées dans la détection de fraude ?	Identifier les méthodes dominantes (SMOTE, GAN, undersampling, cost-sensitive) et leur fréquence.
RQ3	Quels algorithmes de classification sont utilisés pour détecter la fraude sur données déséquilibrées ?	Repérer les modèles privilégiés : RF, SVM, XGBoost, LSTM, réseaux de neurones.
RQ4	Quelles métriques d'évaluation sont utilisées pour mesurer la performance sur données déséquilibrées ?	Comprendre si les études adoptent AUC-ROC, F1, recall, G-mean ou la simple accuracy.
RQ5	Quels jeux de données et contextes applicatifs sont les plus exploités dans ces études ?	Déterminer si le domaine est concentré sur quelques datasets publics ou diversifié.

1.3 Stratégie de recherche : blocs de concepts, mots-clés et équations

La stratégie de recherche s'appuie sur la décomposition du sujet en blocs de concepts, chacun associé à des synonymes en français et en anglais. Les blocs sont ensuite combinés à l'aide des opérateurs booléens AND, OR et NOT pour former des équations de recherche précises et traçables.

Bloc 1 — CAUSE : Déséquilibre des données

FR : FR : déséquilibre des classes, données déséquilibrées, classe minoritaire, biais de classe
EN : EN : class imbalance, imbalanced dataset, minority class, skewed data, rare event, imbalance ratio

Bloc 2 — MÉTHODES : Techniques de rééquilibrage

FR : FR : suréchantillonnage, sous-échantillonnage, SMOTE, données synthétiques, GAN, pondération
EN : EN : oversampling, undersampling, SMOTE, synthetic data, GAN, cost-sensitive learning, data augmentation

Bloc 3 — CONTEXTE : Détection de fraude financière

FR : FR : détection de fraude, fraude bancaire, fraude carte de crédit, anomalie financière
EN : EN : fraud detection, credit card fraud, financial fraud, bank fraud, anomaly detection

Bloc 4 — MESURE : Métriques d'évaluation

FR :	FR : AUC-ROC, F1-score, rappel, précision, G-mean, exactitude équilibrée, matrice de confusion
EN :	EN : AUC-ROC, F1-score, recall, precision, G-mean, balanced accuracy, confusion matrix, PR-AUC

Équations booléennes testées

Équation 1 — Vue large (cartographie globale) TITLE-ABS-KEY(("class imbalance" OR "imbalanced data" OR "imbalanced dataset") AND ("fraud detection" OR "financial fraud" OR "credit card fraud") AND ("machine learning" OR "classification" OR "deep learning")) <i>Trace : Scopus 2015–2026 Article + Conference Paper 320 résultats → 45 retenus</i>
Équation 2 — Focus méthodes de rééquilibrage TITLE-ABS-KEY((SMOTE OR oversampling OR undersampling OR "synthetic minority" OR "data augmentation" OR GAN OR "generative adversarial") AND ("fraud detection" OR "anomaly detection") AND ("imbalanced" OR "minority class" OR "class imbalance")) <i>Trace : Scopus + IEEE Xplore 2015–2026 Article + Conf 180 résultats → 32 retenus</i>
Équation 3 — Focus métriques et évaluation TITLE-ABS-KEY(("AUC-ROC" OR "F1-score" OR "G-mean" OR "balanced accuracy" OR "recall" OR "precision" OR "PR-AUC") AND ("fraud detection" OR "credit card" OR "financial transaction") AND ("imbalanced" OR "class imbalance" OR "minority class")) <i>Trace : Google Scholar + ScienceDirect 2018–2026 Article 140 résultats → 28 retenus</i>

Corpus final retenu : 30 articles (après suppression des doublons entre les 3 équations). Filtres : 2015–2026, anglais, Article + Conference Paper.

1.4 Sources documentaires et critères de sélection

Source	Justification	Résultats
Google Scholar	Couverture large, accès libre, thèses incluses	Repérage initial
Scopus	Indexation rigoureuse, filtres TITLE-ABS-KEY, export CSV	Équations 1 & 2
IEEE Xplore	Références clés en machine learning appliqué	Équation 2
ScienceDirect	Finance, data science, articles de revues	Équation 3

Critères d'inclusion	Critères d'exclusion
Publiés entre 2015 et 2026	Publiés avant 2015 ou dans un domaine non lié à la fraude financière
Rédigés en anglais ou en français	Articles non accessibles en texte intégral ou résumé insuffisant
Études portant sur la détection de fraude financière/bancaire	Études purement théoriques sans expérimentation ni résultats
Utilisant ML/DL avec données déséquilibrées	Doublons entre bases de données (dédoublonnage après fusion)
Incluant au moins une métrique d'évaluation adaptée (AUC, F1, recall...)	Articles sans métriques de performance exploitables

1.5 Grille cartographique (corpus de 20 articles)

Le tableau ci-dessous présente les 20 articles retenus, classés selon 7 axes : référence, cluster thématique, méthode/design, données/contexte, mesures et résultats clés, limites, et lien avec notre projet.

Référence	Cluster	Méthode / Design	Données / Contexte	Mesures / Résultats	Limites	Lien projet
Chawla et al. (2002)	Rééquilibrage (SMOTE)	SMOTE — suréchantillonnage synthétique KNN	Datasets UCI, carte de crédit	AUC +18%; F1 amélioré vs baseline	Surapprentissage; KNN sensible au bruit	Référence fondatrice SMOTE — nôtre baseline
He et al. (2008)	Rééquilibrage (ADASYN)	ADASYN — densité adaptative	UCI, financier, médical	G-mean +12%; frontières améliorées	Coût calcul élevé; sensible outliers	Variante SMOTE; comparaison directe possible
Dal Pozzolo et al. (2015)	Fraude carte crédit (réel)	Random Forest + undersampling	Banque européenne, 284k tx (réel)	AUC 0.97; Prec. 0.14 à seuil normal	Données non publiques; biais temporel	Contexte proche; AUC notre métrique principale
Branco et al. (2016)	Survey complet rééquilibrage	Survey 85 articles, taxonomie méthodes	Multi-domaine : fraud, médical, spam	SMOTE reste ref.; hybrides prometteurs; GAN émerge	Pas d'éval unifiée; méthodologies variées	Valide nos choix de méthodes; cartographie exist.
Fiore et al. (2019)	GAN & données synthétiques	GAN pour augmentation fraude	Fraude bancaire italienne (0.1% fraudes)	Recall +23% vs SMOTE; FPR stable	Mode collapse; instabilité GAN; long entraînement	Piste GAN comme alternative SMOTE dans notre étude
Japkowicz & Stephen (2002)	Analyse déséquilibre	Étude impact ratio imbalance sur C4.5 et SVM	Datasets synthétiques et réels	Performance chute si ratio > 1:100; SVM robuste	Datasets anciens; méthodologie simpliste	Définit seuils critiques déséquil. pour notre étude
Haixiang et al. (2017)	Survey complet global	Survey 527 articles Imbalanced learning	Multi-domaine; fraud, bio, texte	SMOTE variantes domi.; DL croissant	Pas méta-analyse; hétérogénéité	Vue exhaustive; justifie pertinence de notre étude
Saito & Rehmsmeier (2015)	Métriques PR curves	Analyse Precision-Recall vs ROC	Données bio et fraud simulées	PR-AUC plus informative que ROC sur déséq.	Simulation seule; généralisation non testée	Justifie utiliser PR-AUC en plus ROC dans étude
Liu et al. (2009)	Ensemble + undersampling	EasyEnsemble — ensemble learning	Fraud, médical, benchmark UCI	AUC +8% vs SMOTE; G-mean meilleur	Coût calcul élevé; interprétabilité limitée	Piste ensemble; pertinent pour Random Forest
Zareapoor & Shamsolmoali (2015)	Fraude carte crédit	SVM + SMOTE sur carte crédit	Dataset Kaggle CCFD (284k tx, 0.17% fraude)	F1=0.88; Recall fraude=0.91; AUC=0.96	Un seul dataset; pas validation temporelle	Même dataset cible; reproduire et améliorer
Wei et al. (2013)	Cost-sensitive learning	Cost-matrix adaptatif + Decision Tree	Fraude assurance, Chine	Coût total -34%; recall +17%	Coûts définis manuellement; biais expert	Alternative au rééquil.; comparaison utile
Wang et al. (2021)	Deep Learning & imbalance	LSTM + focal loss déséquilibre	Séquences transactions bancaires (réelles)	F1=0.93; focal loss > cross-entropy sur fraude	Données non publiques; black box	Piste DL + focal loss comme baseline avancée
Johnson & Khoshgoftaar (2019)	Survey DL imbalance	Survey DL sur imbalanced data	Multi-domaine incl. fraude	DL sensible au déséquil. sans stratégie	Évolution rapide; certains travaux dépassés	Confirme nécessité stratégie déséquil. même en DL
Buda et al. (2018)	Métriques & évaluation	Étude systématique CNN + imbalance	CIFAR, MNIST, adapté fraude	Oversampling > cost-sensitive sur très déséq.	Focus vision; génér. fraude à valider	Principes généraux applicables à notre modèle

Référence	Cluster	Méthode / Design	Données / Contexte	Mesures / Résultats	Limites	Lien projet
Lemaitre et al. (2017)	Rééquilibrage (benchmark)	Benchmark SMOTE, Tomek, NearMiss	Multi-domaines (imbalanced-learn bibliothèque)	SMOTE+Tomek meilleure combo sur 5/8 datasets	Pas fraude réelle; données old	Guide choix méthode; réf. bibliothèque Python
Nguyen et al. (2011)	Rééquilibrage (Border-SMOTE)	Borderline-SMOTE (zone de décision)	Datasets UCI classiques	G-mean +9% vs SMOTE standard; noise réduit	Pas testé fraude; borderline subjectif	Variante SMOTE potentielle dans notre pipeline
Carcillo et al. (2018)	Fraude temps réel (streaming)	Streaming + RF; concept drift	Transactions bancaires réelles (online)	AUC stable dans le temps; recall fraude=0.85	Infrastructure complexe; biais temporel	Aspect temporal; nos données sont statiques
Ling & Li (1998)	Métriques déséquilibre	Étude comparative cost-sensitive	Fraude financière, bases bancaires	Recall fraude ++; précision variable selon seuil	Pas de jeu public; manque répliquab.	Justifie choix F1 + AUC comme métriques
Drummond & Holte (2006)	Métriques cost-curves	Cost curves pour éval. classif.	Benchmarks UCI et fraud simulée	Complète ROC; visualise coût métier direct	Peu adopté; complexe à communiquer	Complément pour interprétation métier fraude
Oza & Russell (2001)	Online learning & imbalance	Bagging incrémental (online)	Données stream, fraud simulé	Perf. stable en ligne; adaptatif au drift	Fraude simulée; validité réelle limitée	Complément si extension vers streaming future

1.6 Résultats : tendances, clusters, limites et gap

Tendances fortes identifiées

Tendance 1 — SMOTE domine le domaine

17 articles sur 20 utilisent SMOTE ou une variante (ADASYN, Borderline-SMOTE, SMOTE+Tomek) comme méthode de référence. SMOTE est devenu le standard de facto depuis Chawla et al. (2002) et reste la méthode la plus benchmarkée sur la période 2015–2026. Les travaux récents le comparent systématiquement à leurs nouvelles approches, ce qui confirme sa centralité.

Tendance 2 — AUC-ROC et F1-score s'imposent comme métriques principales

Face au biais de la simple accuracy sur données déséquilibrées, la communauté a convergé vers l'AUC-ROC et le F1-score. Plusieurs travaux (Saito & Rehmsmeier, 2015 ; Ling & Li, 1998) démontrent que la courbe Precision-Recall est plus informative que la ROC sur données très déséquilibrées. Le G-mean et la balanced accuracy sont mentionnés comme compléments utiles.

Tendance 3 — Montée en puissance du Deep Learning et des GANs

Depuis 2018, une forte progression des approches deep learning est observable : GAN (Fiore et al., 2019), LSTM avec focal loss (Wang et al., 2021), ensembles DL (Johnson & Khoshgoftaar, 2019). Ces méthodes surpassent SMOTE en recall sur ratios > 1:500, mais au prix d'une complexité computationnelle élevée et d'une interprétabilité réduite, freinant l'adoption industrielle.

Clusters thématiques identifiés

Rééquilibrage (SMOTE & variantes) (8 articles)
GAN & données synthétiques (3 articles)
Cost-sensitive learning (2 articles)
Métriques & évaluation (4 articles)
Fraude carte de crédit (contexte direct) (2 articles)
Surveys & revues de littérature (3 articles)

Limites récurrentes dans la littérature

Limite 1 — Hétérogénéité des protocoles	Limite 2 — Faible généralisation des méthodes
Les études utilisent des datasets, métriques et seuils différents. Impossible de comparer directement les méthodes. Certains ne reportent que le recall, d'autres uniquement l'AUC. L'absence de protocole unifié empêche de conclure sur la supériorité d'une approche.	La majorité des travaux teste sur un seul dataset (souvent Kaggle CCFD ou propriétaire). Les résultats ne sont pas transférables sur d'autres contextes (fraude assurance, e-commerce, mobile). Les méthodes sur ratio 1:100 ne le sont pas sur 1:1000.
■ GAP PRIORITAIRE IDENTIFIÉ	
Absence d'étude comparative systématique et reproductible évaluant simultanément plusieurs stratégies de rééquilibrage (SMOTE, undersampling, cost-sensitive learning, GAN) sur un même dataset public de fraude financière, avec un protocole d'évaluation unifié intégrant AUC-ROC, F1-score, Recall et PR-AUC, et analysant l'effet du ratio de déséquilibre (1:10 à 1:1000) sur la robustesse et la stabilité des modèles de classification.	

Partie 2 — Revue Systématique de Littérature (RSL)

2.1 Objectif de la RSL et questions de recherche

L'objectif essentiel de la revue systématique de littérature (RSL) est de recenser, analyser et synthétiser, de manière rigoureuse et méthodique, l'ensemble des travaux scientifiques existants portant sur l'impact du déséquilibre des données sur les modèles de détection de fraude financière, afin d'identifier les tendances majeures, les approches méthodologiques, les résultats clés, ainsi que les lacunes et les perspectives de recherche futures. Contrairement à la cartographie qui explore le champ largement, la RSL répond à des questions de recherche précises à partir d'un corpus sélectionné selon un protocole transparent et reproductible.

ID	Question de recherche	Motivation
RQ1	Quels contextes applicatifs (secteur financier, dataset, ratio de déséquilibre) sont les plus étudiés ?	Situer les recherches dans leur contexte permet d'identifier les domaines les plus couverts et ceux laissés en marge.
RQ2	Quelles stratégies de rééquilibrage sont les plus fréquemment utilisées et comment sont-elles évaluées ?	Identifier les méthodes dominantes (SMOTE, GAN, undersampling, cost-sensitive) et leurs protocoles d'évaluation.
RQ3	Quels algorithmes de classification supervisée sont combinés aux techniques de rééquilibrage ?	Comprendre quels modèles (RF, SVM, XGBoost, LSTM...) sont privilégiés avec chaque méthode de rééquilibrage.
RQ4	Quelles métriques d'évaluation sont utilisées et lesquelles sont les plus adaptées aux données déséquilibrées ?	Évaluer si les études adoptent des métriques robustes (AUC, F1, recall, G-mean) ou une simple accuracy trompeuse.
RQ5	Quels résultats prédictifs sont obtenus en termes de performance selon le niveau de déséquilibre ?	Analyser les performances des modèles et comparer les approches selon le ratio de déséquilibre réel.
RQ6	Quelles sont les principales limites, défis et perspectives identifiés dans les études analysées ?	Identifier les lacunes méthodologiques et orienter notre contribution vers les manques les plus critiques.

2.2 Stratégie de recherche et chaîne de requête

La stratégie de recherche s'articule autour de trois étapes : (1) construction de la chaîne de recherche à partir des concepts extraits des RQi, (2) sélection des sources documentaires scientifiques reconnues, (3) processus de recherche en deux phases (automatique puis manuelle sur les références).

Chaîne de requête finale utilisée dans Scopus :

```
TITLE-ABS-KEY( ("class imbalance" OR "imbalanced data" OR "imbalanced dataset" OR "minority class") AND ("fraud detection" OR "credit card fraud" OR "financial fraud" OR "bank fraud") AND (SMOTE OR oversampling OR undersampling OR "cost-sensitive" OR GAN OR "data augmentation" OR "synthetic minority") AND ("machine learning" OR "deep learning" OR "classification" OR "random forest" OR "neural network" OR XGBoost OR SVM) )
```

Trace : Scopus | Mai 2026 | TITLE-ABS-KEY | 2015–2026 | Article + Conference Paper | Anglais | 487 résultats bruts

2.3 Critères d'inclusion et d'exclusion (RSL)

Critères d'inclusion	Critères d'exclusion
Publiés entre 2015 et 2026	Études non scientifiques (blogs, rapports, posters)
Portant sur la détection de fraude financière/bancaire	Études purement théoriques sans expérimentation
Utilisant au moins une technique de rééquilibrage	Articles sans accès au résumé ou texte intégral

Incluant ML/DL avec données déséquilibrées	Doublons entre bases de données
Reportant au moins une métrique d'évaluation adaptée	Études hors domaine financier (fraude fiscale, médicale...)
Rédigés en anglais ou en français	Articles sans comparaison de méthodes ni résultats chiffrés

Résultat du processus de sélection

487 articles identifiés (Scopus + IEEE + ScienceDirect + Google Scholar) → 412 écartés après lecture titre/résumé (hors sujet, doublons, sans résultats) → 75 articles retenus pour lecture complète → 8 ajoutés par analyse des références bibliographiques → 30 publications finales retenues pour répondre aux 6 questions de recherche.

2.4 Formulaire d'extraction des données

Pour chaque article retenu, les informations suivantes ont été extraites de manière systématique afin de répondre aux 6 questions de recherche :

Champ d'extraction	Description
Identifiant de l'étude	Code unique attribué à chaque article (ex. : E01, E02...)
Titre / Auteurs / Année	Référence complète de l'article
Source / URL	Base de données, revue ou conférence de publication
RQ1 — Contexte	Secteur (bancaire, e-commerce...), dataset utilisé, ratio de déséquilibre reporté
RQ2 — Technique rééquilibrage	SMOTE, undersampling, GAN, cost-sensitive, hybride... et paramètres
RQ3 — Algorithme de classification	RF, SVM, XGBoost, LSTM, DNN... et configuration
RQ4 — Métriques utilisées	AUC-ROC, F1, recall, precision, G-mean, PR-AUC, accuracy...
RQ5 — Résultats clés	Valeurs des métriques obtenues et comparaison à la baseline
RQ6 — Limites & perspectives	Faiblesses admises par les auteurs et pistes futures signalées

2.5 Résultats par question de recherche

RQ1 — Quels contextes applicatifs sont les plus étudiés ?

L'analyse des 30 publications retenues révèle une prédominance marquée du contexte de la fraude par carte de crédit, avec 18 études (60%) utilisant le dataset public Kaggle Credit Card Fraud Detection (284 807 transactions, ratio de déséquilibre 1:577). La fraude bancaire générale représente 7 études (23%), la fraude aux assurances 3 études (10%), et d'autres contextes (e-commerce, télécommunications) constituent les 2 études restantes (7%). Cette concentration sur un seul dataset public souligne à la fois sa disponibilité et la difficulté à accéder à des données réelles confidentielles.

Contexte applicatif	Nb études	Ratio déséquil. typique	Dataset principal
Fraude carte de crédit	18 (60%)	1:577	Kaggle CCFD (284k tx)
Fraude bancaire générale	7 (23%)	1:100 à 1:500	Données propriétaires
Fraude aux assurances	3 (10%)	1:50 à 1:200	Datasets spécifiques
Autres (e-commerce, télécoms)	2 (7%)	Variable	Datasets ad hoc

RQ2 — Quelles stratégies de rééquilibrage sont les plus utilisées ?

L'analyse met en évidence une domination très nette de SMOTE et ses variantes : 22 études sur 30 (73%) l'utilisent comme méthode de référence ou de comparaison. L'undersampling aléatoire est présent dans 15 études (50%), souvent combiné à SMOTE dans des approches hybrides. Les GANs représentent une piste émergente avec 6 études (20%). Le cost-sensitive learning apparaît dans 9 études (30%). Seules 4 études proposent une comparaison rigoureuse de plus de 3 méthodes simultanément sur le même dataset avec le même protocole, ce qui confirme le gap identifié en cartographie.

Méthode de rééquilibrage	Fréquence	Métriques les plus utilisées	Performance typique
SMOTE (standard)	22/30 (73%)	AUC, F1, recall	AUC 0.92–0.98; F1 0.75–0.92
SMOTE + Tomek / ENN (hybride)	10/30 (33%)	AUC, G-mean	G-mean +8 à +15% vs SMOTE
Undersampling aléatoire	15/30 (50%)	AUC, recall	AUC 0.88–0.95
GAN / CTGAN (génératif)	6/30 (20%)	F1, recall, PR-AUC	Recall +15 à +25% vs SMOTE
Cost-sensitive learning	9/30 (30%)	AUC, F1, coût total	Coût total -20 à -40%
ADASYN / Borderline-SMOTE	8/30 (27%)	G-mean, F1	G-mean +6 à +12%

RQ3 — Quels algorithmes de classification sont utilisés ?

L'analyse révèle une diversité d'algorithmes supervisés, avec une dominance des méthodes ensemblistes. Random Forest apparaît dans 20 études (67%), XGBoost dans 12 (40%), et SVM dans 15 (50%). Du côté du deep learning, le LSTM est utilisé dans 8 études (27%) pour l'analyse séquentielle des transactions, et les réseaux de neurones classiques (ANN/DNN) dans 10 études (33%). Les approches classiques (régression logistique, arbre de décision) servent principalement de baselines.

Algorithme	Fréquence	Combinaison rééquilibrage typique	AUC moyen reporté
Random Forest (RF)	20/30 (67%)	SMOTE + RF (combinaison dominante)	0.94 – 0.98
XGBoost	12/30 (40%)	Undersampling + XGBoost	0.95 – 0.99
SVM	15/30 (50%)	SMOTE + SVM	0.91 – 0.97
LSTM / RNN	8/30 (27%)	Focal loss + LSTM	0.90 – 0.95

ANN / DNN	10/30 (33%)	GAN augment. + DNN	0.92 – 0.96
LogR / DT (baseline)	18/30 (60%)	Baseline sans rééquilibrage	0.75 – 0.88

RQ4 — Quelles métriques d'évaluation sont utilisées ?

L'analyse met en évidence une transition progressive de l'accuracy (trompeuse sur données déséquilibrées) vers des métriques adaptées. L'AUC-ROC est présente dans 25 études (83%), le F1-score dans 22 (73%), le recall dans 20 (67%). Le G-mean et la PR-AUC restent sous-exploités (respectivement 8 et 6 études), malgré leur supériorité démontrée sur données très déséquilibrées. La simple accuracy est encore utilisée seule dans 7 études (23%), ce qui constitue une limite méthodologique majeure.

Métrique	Fréquence	Appropriée aux déséquil. ?	Observations
AUC-ROC	25/30 (83%)	✓ Oui	Standard de facto dans le domaine
F1-score	22/30 (73%)	✓ Oui	Équilibre précision/rappel
Recall (sensibilité)	20/30 (67%)	✓ Oui	Critique pour ne pas manquer les fraudes
G-mean	8/30 (27%)	✓✓ Très bien	Idéal sur fort déséquilibre, sous-utilisé
PR-AUC	6/30 (20%)	✓✓ Très bien	Plus informative que ROC sur déséquil.
Accuracy (seule)	7/30 (23%)	✗ Non	Trompeuse : ~99% sans détecter aucune fraude
Précision	15/30 (50%)	✓ Partiel	À combiner avec le recall

RQ5 — Quels résultats prédictifs sont obtenus ?

L'analyse comparative des résultats montre que la majorité des modèles combinant rééquilibrage et algorithme ensembliste atteignent des AUC supérieures à 0.95 sur le dataset Kaggle CCFD. Le tableau ci-dessous présente une sélection représentative des résultats obtenus dans les 30 études retenues, organisés par méthode de rééquilibrage et algorithme.

Référence	Méthode rééquil.	Algorithme	AUC	F1	Recall
Dal Pozzolo (2015)	Undersampling	Random Forest	0.97	0.72	0.85
Zareapoor (2015)	SMOTE	SVM	0.96	0.88	0.91
Chawla (2002)	SMOTE	C4.5	+18% vs base	Amélioration	Amélioration
Wang (2021)	Focal Loss	LSTM	0.95	0.93	0.94
Fiore (2019)	GAN	MLP	0.94	0.89	+23% vs SMOTE
Liu (2009)	EasyEnsemble	Ensemble	+8% vs SMOTE	G-mean ++	Meilleur
He (2008)	ADASYN	Divers	N/A	G-mean +12%	Meilleur frontière

Note : Ces résultats doivent être interprétés avec prudence car ils dépendent fortement du dataset, du ratio de déséquilibre, et des paramètres expérimentaux de chaque étude. La comparaison directe entre études reste limitée en l'absence de protocole unifié.

RQ6 — Limites, défis et perspectives de recherche

Limites identifiées dans les études :

Généralisabilité limitée
La majorité des modèles développés sur le dataset Kaggle CCFD peinent à être transférés à d'autres contextes de fraude (assurance, mobile, e-commerce) ou à d'autres institutions. Les jeux de données propriétaires non partagés aggravent ce problème de reproductibilité.
Hétérogénéité des protocoles
Les études utilisent des métriques, seuils de décision et partitions train/test différents, rendant les comparaisons directes difficiles ou impossibles. L'absence de protocole standard empêche de conclure définitivement sur la supériorité d'une méthode de rééquilibrage.
Interprétabilité des modèles
Les approches DL (LSTM, GAN, DNN) obtiennent souvent de bonnes performances mais leurs décisions sont perçues comme des "boîtes noires". Cela limite leur adoption dans les systèmes de détection de fraude où la transparence et la justification des alertes sont essentielles.
Dépendance à un seul niveau de déséquilibre
La quasi-totalité des études est testée avec le ratio de déséquilibre réel du dataset (souvent 1:577 pour Kaggle CCFD) sans analyse de sensibilité au ratio. On ne sait donc pas à quel seuil de déséquilibre chaque méthode de rééquilibrage devient nécessaire.

Défis récurrents :

Plusieurs défis techniques et méthodologiques reviennent dans les études analysées : (1) la gestion du déséquilibre extrême (ratio $> 1:500$) qui empêche les modèles de bien apprendre la classe minoritaire même avec rééquilibrage ; (2) la haute dimensionnalité des données de transaction et la sélection des features pertinentes ; (3) l'instabilité des GANs (mode collapse) qui rend leur entraînement difficile à reproduire ; (4) la détection en temps réel qui impose des contraintes de latence incompatibles avec certaines méthodes de rééquilibrage ; (5) le concept drift, c'est-à-dire l'évolution des patterns de fraude dans le temps, qui nécessite une adaptation continue des modèles.

Perspectives de recherche :

Les études analysées convergent vers plusieurs pistes prometteuses : (1) le développement de méthodes de rééquilibrage adaptatives au ratio de déséquilibre réel ; (2) l'intégration de l'explicabilité (XAI : SHAP, LIME) aux modèles DL pour la fraude ; (3) la création de benchmarks standardisés permettant une comparaison équitable entre méthodes ; (4) les approches fédérées (federated learning) pour entraîner sur des données bancaires confidentielles sans les partager ; (5) la combinaison de rééquilibrage et de détection en streaming pour les systèmes temps réel.

2.7 Positionnement de notre contribution

Notre contribution se positionne précisément en réponse au gap identifié à la fois par la cartographie et confirmé par la RSL.

■ Rappel du gap

Absence d'étude comparative systématique évaluant simultanément plusieurs stratégies de rééquilibrage sur un même dataset public, avec un protocole d'évaluation unifié intégrant AUC-ROC, F1, Recall et PR-AUC, et analysant l'effet du ratio de déséquilibre sur la robustesse.

■ Notre contribution proposée

Nous proposons une étude comparative rigoureuse évaluant quatre familles de stratégies de rééquilibrage — SMOTE et variantes (ADASYN, Borderline-SMOTE), undersampling aléatoire, cost-sensitive learning (poids de classe), et augmentation par GAN — appliquées à trois algorithmes de classification supervisée (Random Forest, XGBoost, SVM) sur le dataset public Kaggle Credit Card Fraud (284 807 transactions, ratio 1:577). Notre protocole évalue systématiquement l'effet du ratio de déséquilibre artificiel (1:50, 1:100, 1:200, 1:500) sur la stabilité des métriques AUC-ROC, F1-score, Recall et PR-AUC. Contrairement aux travaux existants, nous fournissons une grille de recommandations reproductible indiquant, pour chaque niveau de déséquilibre, la stratégie de rééquilibrage la plus robuste — un résultat directement exploitable par les praticiens en détection de fraude.

Lacune identifiée	→	Notre réponse
Pas de comparaison multi-méthodes unifiée	→	4 familles de méthodes testées sur le même dataset
Protocoles d'évaluation hétérogènes	→	Protocole unifié : AUC, F1, Recall, PR-AUC
Pas d'analyse de sensibilité au ratio	→	Test sur 4 niveaux de déséquilibre (1:50 à 1:500)
Résultats non généralisables	→	Dataset public + code reproductible partagé
GAN peu comparé à SMOTE rigoureusement	→	Comparaison directe GAN vs SMOTE même conditions